

# Projet Proba : Analyse des facteurs influençant la popularité des chansons sur Spotify

## 1. Introduction

La grande popularité des plateformes de streaming musical comme Spotify a généré une multitude de données sur les habitudes d'écoute et la popularité des chansons. L'analyse de ces données nous aide à comprendre ce qui fait le succès des chansons et peut éclairer les décisions de l'industrie musicale, les systèmes de recommandation et les expériences utilisateur personnalisées.

Ce projet vise à explorer les facteurs qui influencent la popularité des chansons sur Spotify à l'aide de Hypothesis testing et Regression analysis. On utilise un jeu de données de Kaggle pour examiner les relations entre les caractéristiques des chansons, les informations sur l'artiste, la date de sortie et différentes mesures de popularité.

## 2. Le jeu de données

Les données utilisées dans ce projet proviennent des sources suivantes :

[Spotify - All Time Top 2000s Mega Dataset \(kaggle.com\)](https://www.kaggle.com/datasnaek/tmdb-5000-movie-dataset)

- À propos du jeu de données :

Ce jeu de données contient des statistiques audio des 2000 meilleures pistes sur Spotify. Les données contiennent environ 15 colonnes décrivant chacune la piste et ses qualités. Les chansons sorties de 1956 à 2019 sont incluses par certains artistes notables et célèbres comme Queen, The Beatles, Guns N' Roses, etc.

```
> str(data)
'data.frame': 1994 obs. of 15 variables:
 $ Index           : int 1 2 3 4 5 6 7 8 9 10 ...
 $ Title            : chr "Sunrise" "Black Night" "Clint Eastwood" "The Pretender" ...
 $ Artist           : chr "Norah Jones" "Deep Purple" "Gorillaz" "Foo Fighters" ...
 $ Top.Genre        : chr "adult standards" "album rock" "alternative hip hop" "alternative metal" ...
 $ Year             : int 2004 2000 2001 2007 2002 2004 2002 2006 2004 2002 ...
 $ Beats.Per.Minute..BPM.: int 157 135 168 173 106 99 102 137 148 112 ...
 $ Energy            : int 30 79 69 96 82 46 71 96 92 67 ...
 $ Danceability      : int 53 50 66 43 58 54 71 37 36 91 ...
 $ Loudness..dB.     : int -14 -11 -9 -4 -5 -9 -6 -5 -4 -3 ...
 $ Liveness          : int 11 17 7 3 10 14 13 12 10 24 ...
 $ Valence           : int 68 81 52 37 87 14 54 21 23 66 ...
 $ Length..Duration. : chr "201" "207" "341" "269" ...
 $ Acousticness      : int 94 17 2 0 1 0 6 0 0 0 ...
 $ Speechiness       : int 3 7 17 4 3 2 3 14 8 7 ...
 $ Popularity        : int 71 39 69 76 59 45 74 69 77 82 ...
```

## Contenu

- **Index** : ID
- **Title** : Nom de la piste
- **Artist** : Nom de l'artiste
- **Top Genre** : Genre de la chanson
- **Year** : Année de sortie de la chanson
- **Beats per Minute (BPM)** : Le tempo global estimé d'une piste en battements par minute (BPM). Dans la terminologie musicale, le tempo est la vitesse ou le rythme d'un morceau donné et dérive directement de la durée moyenne du battement.
- **Energy** : L'énergie est une mesure de 0 à 100 et représente une mesure perceptuelle de l'intensité et de l'activité.
- **Danceability** : La capacité à danser décrit dans quelle mesure une chanson est adaptée à la danse en fonction d'une combinaison d'éléments musicaux, notamment le tempo, la stabilité du rythme, la force du rythme et la régularité globale. Une valeur de 10 est la moins dansante et 100 est la plus dansante.
- **Loudness** : Volume global d'une piste en décibels (dB). Les valeurs d'intensité sonore sont moyennées sur l'ensemble de la piste et sont utiles pour comparer l'intensité sonore relative des pistes. L'intensité sonore est la qualité d'un son qui est le principal corrélat psychologique de la force physique (amplitude). Les valeurs varient généralement entre -60 et 0 dB.
- **Liveness** : Déetecte la présence d'un public dans l'enregistrement. Des valeurs de vivacité plus élevées représentent une probabilité accrue que le chanson ait été joué en direct
- **Valence**: Une mesure de 0 à 100 décrivant la positivité musicale véhiculée par un morceau. Les pistes à valence élevée semblent plus positives (par exemple joyeuses, joyeuses, euphoriques), tandis que les pistes à faible valence semblent plus négatives (par exemple tristes, déprimées, en colère).
- **Length** : La durée de la chanson en secondes.

- **Acoustic** : Mesure de confiance de 0 à 100 indiquant si la piste est acoustique. 100 représente une grande confiance dans le fait que la piste est acoustique.
- **Speechiness** : Speechiness détecte la présence de mots prononcés dans une piste. Plus l'enregistrement ressemble exclusivement à de la parole (par exemple, talk-show, livre audio, poésie), plus la valeur de l'attribut est proche de 100. Les valeurs supérieures à 66 décrivent des pistes probablement entièrement composées de paroles. Les valeurs comprises entre 33 et 66 décrivent des pistes pouvant contenir à la fois de la musique et de la parole, soit en sections, soit en couches, y compris dans des cas tels que la musique rap. Les valeurs inférieures à 33 représentent très probablement de la musique et d'autres pistes non vocales.
- **Popularity** : Plus la valeur est élevée, plus la chanson est populaire.

### 3. L'analyse exploratoire des données (EDA)

L'EDA est une étape cruciale dans la compréhension des caractéristiques de l'ensemble de données, l'identification des problèmes potentiels et l'obtention d'informations qui guident une analyse plus approfondie. Tout d'abord, on vérifie les valeurs manquantes dans l'ensemble de données à l'aide de la fonction `is.na(data)` :

```
> total_missing <- sum(is.na(data))
> print(paste0("Total missing values in the dataset: ", total_missing))
[1] "Total missing values in the dataset: 0"
```

Il n'existe pas de NA valeurs dans l'ensemble de données.

Ensuite, on renomme les colonnes "Durée", "BPM", "Loudness" pour un traitement plus facile ultérieurement :

```
> data <- rename(data,
+                  "Duration" = "Length..Duration.",
+                  "BPM" = "Beats.Per.Minute..BPM.",
+                  "Loudness_db" = "Loudness..dB.")
>
```

La "Duration" est lue comme un type de données différent (caractère ou facteur), ce qui serait inapproprié pour les calculs numériques, on utilise la fonction `as.integer()` pour convertir cette colonne en type de données entier. Il existe des valeurs NA après la conversion, on les supprime donc de l'ensemble de données.

```
> data$Duration <- as.integer(data$Duration)
Warning message:
NAs introduced by coercion
> total_missing <- sum(is.na(data))
> print(paste0("Total missing values in the dataset: ", total_missing))
[1] "Total missing values in the dataset: 4"
> data <- na.omit(data)
```

Ensuite, nous traitons avec "Top Genre", qui est composé de valeurs catégoriques et de nombreux types (album rock, art pop, british folk, adults standards, etc.)

```

> top_genre_counts <- table(data$Top.Genre) %>%
+   sort(decreasing = TRUE)
>
> print(top_genre_counts)

          album rock      adult standards      dutch pop      alternative rock
            411                  123                  88                  86
        dance pop      dutch indie                  75                  70
        dance rock      dutch cabaret                  51                  49
          pop                  art rock                  40                  38
      irish rock      british soul                  31                  27
          disco      dutch rock                  18                  17
alternative dance      art pop                  14                  14
          funk      dutch americana                  12                  11
      classic soul      mellow gold                  11                  10
      chanson      german pop                   9                   8
        blues                  folk                   8                   8
      big room      canadian folk                  7                   7
detroit hip hop      electro                   7                   7
      boy band      brill building pop                  6                   6
        celtic      classic country pop                  5                   5
    acoustic pop      belgian pop                   4                   4
      dutch metal      folk-pop                   4                   4
      reggae fusion      australian rock

```

On regroupe les genres dans les 7 genres les plus populaires et une catégorie "Others" en utilisant les fonctions `mutate()` et `case_when()`. Si un genre correspond à l'une des chaînes spécifiées, il est remplacé par un nouveau nom de genre correspondant (comme "adult.standards", "soul", etc.). Tous les autres genres sont regroupés dans la catégorie "Others".

```

> data <- mutate(data,
+                 Top.Genre = case_when(
+                     str_detect(Top.Genre, "adult standards") ~ "adult standards",
+                     str_detect(Top.Genre, "soul") ~ "soul",
+                     str_detect(Top.Genre, "alternative") ~ "alternative",
+                     str_detect(Top.Genre, "dance") ~ "dance",
+                     str_detect(Top.Genre, "indie") ~ "indie",
+                     str_detect(Top.Genre, "hip hop|rap") ~ "hip hop/rap",
+                     str_detect(Top.Genre, "rock|prog") ~ "rock",
+                     str_detect(Top.Genre, "pop") ~ "pop",
+                     TRUE ~ "Others"
+                 )
+ )
> top_genre_counts <- table(data$Top.Genre) %>%
+   sort(decreasing = TRUE)
>
> print(top_genre_counts)

```

Genre	Count
rock	710
Others	376
soul	45
hip hop/rap	28
pop	302
alternative	187
dance	138
adult standards	123
indie	81

On convertit la colonne "Top Genre" en facteur et la renivelle pour que "Others" soit le niveau de référence. Cela se fait à l'aide des fonctions factor() et relevel(). On a décidé de choisir "Others" comme le référence pour les variables dummies. La raison est que "Others" est un groupe de genres mineurs, ce qui peut conduire à des résultats incorrects pour le modèle, que j'ai regroupé en un seul. Cette étape prépare à la création de variables dummies, car elle permet de spécifier quel niveau doit être la référence par rapport à laquelle les autres niveaux sont comparés.

```
#Create dummies variables for "Top Genre" by choosing "others" as the reference level
data$Top.Genre <- relevel(factor(data$Top.Genre), ref = "others")

# Create the model matrix
genre_dummies <- model.matrix(~ Top.Genre, data = data) [, -1]

# Add dummy variables to the main data frame
data <- cbind(data, genre_dummies)

data <- data[data$Top.Genre != "others", ]
```

Après cela, on crée une matrice de modèle de variables dummies pour la colonne "Top Genre". La première colonne de la matrice, qui représente le niveau de référence "Others", est supprimée. Les variables dummies sont ensuite ajoutées à l'ensemble de données principal.

Pour l'année de sortie, on crée les nouvelles colonnes pour calculer les années depuis la sortie.


```
> followers<-read.csv(file.choose(), header = TRUE, dec = ".")
> data <- merge(data, followers, by = "Artist", all.x = TRUE)
```

Pour l'artiste, on importe le nombre de followers sur Spotify à partir d'un autre jeu de données et les ai fusionnés par noms d'artiste.

```
> followers<-read.csv(file.choose(), header = TRUE, dec = ".")
> data <- merge(data, followers, by = "Artist", all.x = TRUE)
```

## 4. Tests statistiques

Après avoir effectué un nettoyage des données, j'ai étudié la variable cible : Popularity scores. On analyse la distribution de la variable de popularité dans les données en utilisant l'histogramme, le tracé QQ (quantile-quantile) et le test de Shapiro Wilk.



```
> shapiro_test_result <- shapiro.test(data$Popularity)
> print(shapiro_test_result)
```

Shapiro-Wilk normality test

```
data: data$Popularity
W = 0.96753, p-value < 2.2e-16
```

Les résultats montrent que, avec la valeur p était trop petite (valeur p < 2,2e-16), il est peu probable que les données soient distribuées normalement.

Pour résoudre ce problème, on prend un échantillon de 100 observations de la popularité et cela suggère que les données de l'échantillon suivent la distribution normale (valeur p = 0.0747 > 0.05). On utilise cet échantillon pour le reste du projet.

```
> shapiro_test_result <- shapiro.test(data$Popularity)
>
> # Print the test results
> print(shapiro_test_result)
```

Shapiro-Wilk normality test

```
data: data$Popularity
W = 0.9768, p-value = 0.0747
```

Les statistiques descriptives pour chaque variable de l'ensemble de données, en fonction du type de variable :

```
> summary(data)
      BPM          Energy        Danceability    Loudness_db       Liveness       Valence
Min.   : 68.0   Min.   : 5.00   Min.   :20.00   Min.   :-21.00   Min.   : 3.00   Min.   : 3.00
1st Qu.:100.8  1st Qu.:40.50  1st Qu.:45.00  1st Qu.:-12.00  1st Qu.:10.00  1st Qu.:32.00
Median :122.5  Median :63.50  Median :56.00  Median :-9.00   Median :14.00  Median :54.50
Mean   :120.8  Mean   :57.81  Mean   :54.47  Mean   :-9.41   Mean   :21.89  Mean   :52.51
3rd Qu.:136.5  3rd Qu.:77.00  3rd Qu.:64.25  3rd Qu.:-6.00   3rd Qu.:28.00  3rd Qu.:76.00
Max.   :200.0   Max.   :97.00  Max.   :95.00  Max.   :-3.00   Max.   :99.00  Max.   :98.00
      Duration      Acousticness     Speechiness     Popularity Top.Genreadult.standards
Min.   :122.0   Min.   : 0.00   Min.   : 2.00   Min.   :17.00   Min.   : 0.00
1st Qu.:212.8  1st Qu.: 3.75  1st Qu.: 3.00  1st Qu.:49.00  1st Qu.: 0.00
Median :256.0   Median :24.50  Median : 4.00   Median :62.00  Median : 0.00
Mean   :276.0   Mean   :32.98  Mean   : 5.62   Mean   :60.07  Mean   : 0.13
3rd Qu.:298.8  3rd Qu.:64.50  3rd Qu.: 5.00  3rd Qu.:70.00  3rd Qu.: 0.00
Max.   :811.0   Max.   :98.00  Max.   :38.00  Max.   :95.00  Max.   : 1.00
Top.Genrealternative Top.Genredance Top.Genrehiphop.rap Top.Genreindie Top.Genrepop Top.Gennerock
Min.   : 0.00   Min.   : 0.00
1st Qu.: 0.00  1st Qu.: 0.00  1st Qu.: 0.00  1st Qu.: 0.00  1st Qu.: 0.00  1st Qu.: 0.00
Median : 0.00   Median : 0.00   Median : 0.00   Median : 0.00   Median : 0.00   Median : 0.00
Mean   : 0.09   Mean   : 0.06  Mean   : 0.05  Mean   : 0.04  Mean   : 0.13  Mean   : 0.48
3rd Qu.: 0.00  3rd Qu.: 1.00
Max.   : 1.00   Max.   :1.00   Max.   :1.00   Max.   :1.00   Max.   :1.00   Max.   :1.00
Top.Genresoul Years_since_release Total.Followers
Min.   : 0.00   Min.   : 5.00   Min.   : 11979
1st Qu.: 0.00  1st Qu.:17.75  1st Qu.: 559808
Median : 0.00   Median :36.50   Median :1928984
Mean   : 0.02   Mean   :34.16   Mean   : 5734801
3rd Qu.: 0.00  3rd Qu.:50.00  3rd Qu.: 5689252
Max.   : 1.00   Max.   :65.00   Max.   :62743762
```

Ensuite, on applique un test t de Welch Two Sample, qui est un test statistique utilisé pour déterminer si deux moyennes de population sont égales, à deux ensembles de données, "pop\_popularity" et "rock\_popularity" dans ce cas.

- Hypothèse nulle (H0) : La popularité moyenne des chansons pop est égale à la popularité moyenne des chansons rock.
- Hypothèse alternative (H1) : La popularité moyenne des chansons pop n'est pas égale à la popularité moyenne des chansons rock.

```
> t_test_result <- t.test(pop_popularity, rock_popularity)
> t_test_result
```

```
Welch Two Sample t-test

data: pop_popularity and rock_popularity
t = -0.72909, df = 15.804, p-value = 0.4766
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-14.382475  7.026705
sample estimates:
mean of x mean of y
56.38462 60.06250
```

t = -0,72909 : Il s'agit de la statistique t, qui est une mesure de la différence entre les deux moyennes par rapport à la variation des données. Le signe négatif indique que la moyenne du premier groupe (pop\_popularity) est inférieure à la moyenne du deuxième groupe (rock\_popularity).

Valeur p = 0,4766 > 0,05 : La valeur p signifie que nous ne rejetons pas l'hypothèse nulle. Dans ce cas, la valeur p est de 0,4766, nous n'avons donc pas suffisamment de preuves pour affirmer que les moyennes de pop\_popularity et rock\_popularity sont différentes.

Intervalle de confiance à 95 % : -14,382475 7,026705 : Il s'agit de la plage de valeurs dans laquelle nous pouvons être sûrs à 95 % que se situe la véritable différence entre les moyennes des deux populations. Puisque cet intervalle contient zéro, il conforte la conclusion selon laquelle les deux moyennes ne sont pas significativement différentes.

moyenne de x 56,38462 et moyenne de y 60,06250 : ce sont les exemples de moyennes de pop\_popularity et rock\_popularity, respectivement. La popularité moyenne pour le genre « pop » est d'environ 56,38, et pour le genre « rock », elle est d'environ 60,06.

On utilise le test d'analyse de variance (ANOVA), qui est un test statistique utilisé pour déterminer s'il existe des différences significatives entre les moyennes de trois groupes ou plus. Dans ce cas, le test est appliqué à la variable Popularité dans différents Top.Genre.

- Hypothèse nulle (H0) : la popularité moyenne est égale selon les différents genres.
- Hypothèse alternative (H1) : La popularité moyenne n'est pas égale selon les genres.

```
> anova_result <- aov(Popularity ~ Top.Genre, data = data_sample)
> summary(anova_result)

   Df Sum Sq Mean Sq F value Pr(>F)
Top.Genre    7  3744   534.9   3.346 0.0032 ***
Residuals  92 14708   159.9
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Dans ce cas, la valeur p = 0,0032 < 0,05, on disposait donc de suffisamment de preuves pour affirmer que la popularité moyenne n'est pas égale selon les genres.

On teste les hypothèses de ANOVA :

A l'aide de Shapiro-Wilk test et Breusch Pagan test, il semble que les hypothèses de normalité et constante variance sont remplies.

```
> shapiro.test(anova_result$residuals)

Shapiro-Wilk normality test

data: anova_result$residuals
W = 0.98459, p-value = 0.2966
```

```
> bptest(anova_result)

studentized Breusch-Pagan test

data: anova_result
BP = 8.4547, df = 7, p-value = 0.2942
```

## 5. Construction de modèles

On supprime les variables inutiles du modèle :

```
data <- data %>% select(-Artist, -Index, -Title, -Top.Genre, -X, -Year)
```

### 5.1. Modèle 1 : Simple Linear Regression

On crée le premier modèle de régression linéaire simple, On a d'abord étudié quelle fonction avait la relation linéaire la plus forte avec "Popularity" :

```
> # Calculate correlation coefficients
> correlations <- sapply(data[numerical_cols], function(x) cor(x, data$Popularity, use = "pairwise.complete.obs"))
>
> # Sort correlations in descending order
> sorted_correlations <- sort(correlations, decreasing = TRUE)
>
> # Print sorted correlations
> print(sorted_correlations)
```

	Total.Followers	Years_since_release	Valence
Popularity	1.0000000000	0.3314673105	0.1736854050
Speechiness	0.1585202667	Loudness_db	Top.Genresoul
Top.Genredance	0.0885920901	0.1431248094	0.1149461414
Energy	0.0008071290	Danceability	Top.Genrehiphop.rap
Top.Genrepop	-0.1048738336	Top.Gennerock	Top.Genrealternative
	0.0728677236	-0.0005304598	BPM
	-0.01283688228	Duration	Acousticness
		-0.1283688228	Liveness
			Top.Genreindie
			-0.3955055110

À partir de ce résultat, on peut voir que "Total.Followers" a la relation linéaire positive la plus forte avec "Popularity" (coefficient de corrélation = 0,331) et que "Top.Genreindie" a la relation linéaire négative la plus forte avec "Popularity" (coefficient de corrélation = -0,395).

```
> # Create the simple linear regression model
> model_1 <- lm(Popularity ~ Total.Followers, data = data)
>
> # Print the summary of the model
> summary(model_1)
```

Call:  
lm(formula = Popularity ~ Total.Followers, data = data)

Residuals:

Min	1Q	Median	3Q	Max
-40.440	-9.711	2.353	9.184	25.939

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	5.739e+01	1.506e+00	38.110	< 2e-16 ***
Total.Followers	4.666e-07	1.342e-07	3.478	0.000755 ***

---


Signif. codes: 0 ‘\*\*\*’ 0.001 ‘\*\*’ 0.01 ‘\*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 12.95 on 98 degrees of freedom  
Multiple R-squared: 0.1099, Adjusted R-squared: 0.1008  
F-statistic: 12.1 on 1 and 98 DF, p-value: 0.0007551

La valeur  $R^2$  est de 0,1099, ce qui signifie qu'environ 11 % de la variabilité de la "Popularité" peut être expliquée par le "Total.Followers". La valeur  $R^2$  est assez faible, ce qui indique que "Total.Followers" n'explique qu'une petite partie de la variabilité de "Popularity".


On teste les hypothèses du modèle :

### 1. Linéarité



En observant la figure, on fait une remarque que la relation linéaire uniquement entre la popularité et la variable indépendante 'Total Followers' n'est pas très claire et précise. Il semble que l'hypothèse de Linéarité est violée.

### 2. Normalité des résidus



```

> # Perform the Shapiro-Wilk test
> shapiro.test(residuals)

Shapiro-Wilk normality test

data: residuals
W = 0.97333, p-value = 0.03999


```

On voit bien sur les figures et le test Shapiro Wilk, avec la valeur  $p = 0.03999 < 0.05$ , que les résiduels ne suivent pas la loi normale. Il suggère que l'hypothèse de normalité ne soit pas remplie pour ce modèle.

### 3. Indépendance

L'hypothèse d'observation indépendante stipule que chaque observation de l'ensemble de données est indépendante. Comme chaque variable est indépendante des autres, l'hypothèse d'indépendance n'est pas violée.

### 4. Constant variance



```
> bptest(model_1)
studentized Breusch-Pagan test
```

```
data: model_1
BP = 0.16241, df = 1, p-value = 0.6869
```

Le résultat du test de Breusch Pagan indiquant que la valeur  $p = 0,68 > 0,05$ , la variance là où il y a des valeurs ajustées est distribuée de manière similaire, validant que l'hypothèse est remplie.

## 5.2. Modèle 2 : Multiple linear regression avec toutes les fonctions

```
> model_2 <- lm(Popularity ~ ., data = data)
>
> # Print the summary of the model
> summary(model_2)

Call:
lm(formula = Popularity ~ ., data = data)

Residuals:
    Min      1Q  Median      3Q     Max 
-26.5916 -5.4394 -0.4419  6.4508 23.9771 

Coefficients: (1 not defined because of singularities)
              Estimate Std. Error t value Pr(>|t|)    
(Intercept) 8.869e+01 1.761e+01 5.036 2.82e-06 ***
BPM         -4.325e-03 5.089e-02 -0.085 0.932484    
Energy       -3.133e-01 1.249e-01 -2.508 0.014121 *  
Danceability -3.646e-02 1.246e-01 -0.293 0.770579    
Loudness_db  1.701e+00 5.675e-01 2.998 0.003607 ** 
Liveness     -1.486e-02 6.369e-02 -0.233 0.816051    
Valence      1.268e-01 7.260e-02 1.747 0.084429 .  
Duration     -1.559e-02 1.212e-02 -1.286 0.201991    
Acousticness -7.838e-02 6.548e-02 -1.197 0.234790    
Speechiness  2.833e-01 2.469e-01 1.148 0.254536    
Top.Genreadult.standards -2.198e+00 8.700e+00 -0.253 0.801184    
Top.Genrealternative 2.357e+00 9.022e+00 0.261 0.794599    
Top.Genredance   2.387e+00 9.309e+00 0.256 0.798245    
Top.Genrehiphop.rap -1.427e+01 1.035e+01 -1.379 0.171640    
Top.Genreindie   -2.255e+01 1.021e+01 -2.208 0.030083 *  
Top.Genrepop     -6.005e+00 8.953e+00 -0.671 0.504271    
Top.Gennerock    -4.270e+00 8.344e+00 -0.512 0.610211    
Top.Genresoul    NA        NA        NA        NA        
Years_since_release 2.476e-01 8.538e-02 2.900 0.004800 ** 
Total.Followers  5.037e-07 1.429e-07 3.525 0.000701 ***

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.03 on 81 degrees of freedom
Multiple R-squared:  0.466,    Adjusted R-squared:  0.3474 
F-statistic: 3.927 on 18 and 81 DF,  p-value: 1.075e-05
```

Le variable "Top.Genresoul" et ne sont pas définies en raison de singularités, ce qui signifie qu'elles peuvent être parfaitement corrélées avec une ou plusieurs autres variables du modèle. En utilisant la fonction alias(), le résultat montre que "Top.Genresoul" est un alias de coefficients.

"Top.Genresoul" est alias avec toutes les variables "Top.Genre", ce qui signifie qu'il peut être exprimé comme une combinaison linéaire des autres variables Top.Genre. En fait, "Top.Genresoul" et les autres variables "Top.Genres" sont des variables dummys créées à partir de la même variable catégorielle, et l'une d'elles (dans ce cas, Top.Genresoul) peut être exprimée comme une combinaison linéaire des autres.

```
> alias_info <- alias(model_2)
>
> # Print the alias information
> print(alias_info)
Model :
Popularity ~ BPM + Energy + Danceability + Loudness_db + Liveness +
  Valence + Duration + Acousticness + Speechiness + Top.Genreadult.standards +
  Top.Genrealternative + Top.Genredance + Top.Genrehiphop.rap +
  Top.Genreindie + Top.Genrepop + Top.Genreroock + Top.Genresoul +
  Years_since_release + Total.Followers

Complete :
      (Intercept) BPM Energy Danceability Loudness_db Liveness Valence Duration Acousticness
Top.Genresoul 1          0   0       0           0        0     0       0           0
               Speechiness Top.Genreadult.standards Top.Genrealternative Top.Genredance
Top.Genresoul 0          -1            -1           -1
               Top.Genrehiphop.rap Top.Genreindie Top.Genrepop Top.Genreroock Years_since_release
Top.Genresoul -1          -1            -1           -1           0
               Total.Followers
Top.Genresoul 0


```

Pour résoudre ce problème, on supprime "Top.Genresoul" du modèle puis le reconstruit

```
> model_2 <- lm(Popularity ~ . - Top.Genresoul, data = data)
>
> # Print the summary of the model
> summary(model_2)

Call:
lm(formula = Popularity ~ . - Top.Genresoul, data = data)

Residuals:
    Min      1Q      Median      3Q      Max 
-26.5916 -5.4394 -0.4419  6.4508 23.9771 

Coefficients:
              Estimate Std. Error t value Pr(>|t|)    
(Intercept) 8.869e+01 1.761e+01 5.036 2.82e-06 ***
BPM         -4.325e-03 5.089e-02 -0.085 0.932484    
Energy       -3.133e-01 1.249e-01 -2.508 0.014121 *  
Danceability -3.646e-02 1.246e-01 -0.293 0.770579    
Loudness_db  1.701e+00 5.675e-01 2.998 0.003607 ** 
Liveness     -1.486e-02 6.369e-02 -0.233 0.816051    
Valence      1.268e-01 7.260e-02 1.747 0.084429 .  
Duration     -1.559e-02 1.212e-02 -1.286 0.201991    
Acousticness -7.838e-02 6.548e-02 -1.197 0.234790    
Speechiness  2.833e-01 2.469e-01 1.148 0.254536    
Top.Genreadult.standards -2.198e+00 8.700e+00 -0.253 0.801184    
Top.Genrealternative  2.357e+00 9.022e+00 0.261 0.794599    
Top.Genredance   2.387e+00 9.309e+00 0.256 0.798245    
Top.Genrehiphop.rap -1.427e+01 1.035e+01 -1.379 0.171640    
Top.Genreindie   -2.255e+01 1.021e+01 -2.208 0.030083 *  
Top.Genrepop     -6.005e+00 8.953e+00 -0.671 0.504271    
Top.Genreroock   -4.270e+00 8.344e+00 -0.512 0.610211    
Years_since_release 2.476e-01 8.538e-02 2.900 0.004800 ** 
Total.Followers  5.037e-07 1.429e-07 3.525 0.000701 *** 
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.03 on 81 degrees of freedom
Multiple R-squared:  0.466,    Adjusted R-squared:  0.3474 
F-statistic: 3.927 on 18 and 81 DF,  p-value: 1.075e-05
```

Dans le modèle, des variables telles que "Danceability", "BPM", "Liveness", "Duration", "Valance", "Speechiness", "Top.Genrealternative", "Top.Genrepop", "Top.Genredance", "Top.Genreroock", et "Top.Genreadult.standards" sont statistiquement significatives au niveau 0,05.

La valeur  $R^2$  est de 0,466, ce qui signifie qu'environ 46.6 % de la variabilité de la "Popularité" peut être expliquée par le modèle.


	BPM	Energy	Danceability	Loudness_db
	1.415696	7.397313	2.894531	3.834144
	Liveness	Valence	Duration	Acousticness
	1.316686	2.997451	1.527984	3.510501
Speechiness	Top.Genreadult.standards	Top.Genrealternative	Top.Genredance	Top.Genreroock
	1.663087	7.036902	5.480209	4.017851
Top.Genrehiphop.rap	Top.Genreindie	Top.Genrepop	Top.Genreroock	14.285624
	4.180408	3.291808	7.451953	
Years_since_release	Total.Followers			
	1.799509	1.563635		

Le facteur d'inflation de variance (VIF) indique le niveau de multicolinéarité dans le modèle:

- "BPM", "Liveness", "Duration", "Speechiness", "Years\_since\_release", "Total.Followers" : ces variables ont des valeurs VIF proches de 1, ce qui suggère qu'elles ne sont pas corrélées avec les autres variables du modèle.
- "Danceability", "Loudness\_db", "Valence", "Acousticness", "Top.Genredance", "Top.Genrehiphop.rap", "Top.Genreindie" : Ces variables ont des valeurs VIF comprises entre 1 et 5, ce qui suggère qu'elles ont une corrélation modérée avec d'autres variables du modèle.
- "Energy", "Top.Genreadult.standards", "Top.Genrealternative", "Top.Genrepop" : ces variables ont des valeurs VIF comprises entre 5 et 10, ce qui suggère qu'elles ont une forte corrélation avec d'autres variables du modèle.
- "Top.Genreroock" : Cette variable a une valeur VIF supérieure à 10, ce qui suggère qu'elle a une très forte corrélation avec d'autres variables du modèle. En effet, il s'agit d'une variable factice créée à partir de la même variable catégorielle.


On teste les hypothèses du modèle :

## 1. Linéarité



La plupart des variables sont non linéaires avec "Popularity", il signifie que l'hypothèse de Linéarité est violée.

## 2. Normalité des résidus



```
> shapiro.test(residuals_2)
```

Shapiro-Wilk normality test

```
data: residuals_2
W = 0.98927, p-value = 0.6057
```


On voit bien sur les figures et le test Shapiro Wilk, avec la valeur  $p = 0.6057 > 0.05$ , que les résiduels suivent la loi normale. Il suggère que l'hypothèse de normalité soit remplie pour ce modèle.

### 3. Indépendance

L'hypothèse d'observation indépendante stipule que chaque observation de l'ensemble de données est indépendante. Comme chaque variable est indépendante des autres, l'hypothèse d'indépendance n'est pas violée.

### 4. Constant variance

Residuals vs. Fitted Values



```
> bptest(model_2)  
studentized Breusch-Pagan test
```

```
data: model_2  
BP = 28.612, df = 18, p-value = 0.05333
```

Le résultat du test de Breusch Pagan indiquant que la valeur  $p = 0.05333 > 0.05$ , la variance là où il y a des valeurs ajustées est distribuée de manière similaire, validant que l'hypothèse est remplie.

### 5.3. Modèle 3 : Multiple linear regression avec fonctions sélectionnées

```
# Create a copy of the data
data_transformed <- data

# Create interaction features
data_transformed$Energy_Danceability <- data$Energy * data$Danceability
data_transformed$BPM_Loudness <- data$BPM * data$Loudness_db
data_transformed$Acousticness_Speechiness <- data$Acousticness * data$Speechiness
data_transformed <- data_transformed %>% select(-Energy, -Danceability, -BPM, -Loudness_db, -Acousticness, -Speechiness, -Top.Genresoul)
```

Tout d'abord, on crée trois nouvelles fonctionnalités d'interaction dans l'ensemble de données « data\_transformed ». Les fonctionnalités d'interaction sont de nouvelles variables créées en multipliant deux variables existantes ensemble. Ils peuvent être utiles dans un modèle de régression pour capturer l'effet de la combinaison de deux variables sur la variable de réponse.

- "Energy\_Danceability" est créé en multipliant "Energy" et "Danceability".
- "BPM\_Loudness" est créé en multipliant "BPM" et "Loudness\_db".
- "Acousticness\_Speechiness" est créé en multipliant "Acousticness" et "Speechiness".

Ensuite, on modifie l'ensemble de données "data\_transformed" pour supprimer certaines colonnes. Les colonnes "Énergie", "Danceability", "BPM", "Loudness\_db", "Acousticness", "Speechiness" et "Top.Genresoul" sont supprimées.

```
> model_3 <- lm(formula, data = data_transformed)
> summary(model_3)
```

```
Call:
lm(formula = formula, data = data_transformed)

Residuals:
    Min      1Q      Median      3Q      Max 
-26.0355 -6.8904   0.3995   7.2626  25.1663 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 5.864e+01 1.144e+01  5.127 1.86e-06 ***
Liveness   -5.043e-02 6.165e-02 -0.818 0.415690  
Valence     9.089e-02 6.868e-02  1.323 0.189277  
Duration    -1.140e-02 1.183e-02 -0.964 0.337994  
Top.Genreadult.standards 2.101e-02 8.789e+00  0.002 0.998098  
Top.Genrealternative  3.394e+00 9.137e+00  0.372 0.711189  
Top.Genredance    3.935e+00 9.332e+00  0.422 0.674359  
Top.Genrehiphop.rap -8.993e+00 9.688e+00 -0.928 0.355938  
Top.Genreindie    -2.398e+01 1.017e+01 -2.358 0.020689 *
Top.Genrepop     -6.815e+00 8.925e+00 -0.764 0.447252  
Top.Genrerock    -2.597e+00 8.441e+00 -0.308 0.759144  
Years_since_release 2.070e-01 8.217e-02  2.520 0.013637 *  
Total.Followers  5.331e-07 1.351e-07  3.945 0.000165 ***  
Energy_Danceability -4.722e-04 1.337e-03 -0.353 0.724885  
BPM_Loudness     5.621e-03 3.119e-03  1.802 0.075100 .  
Acousticness_Speechiness 1.081e-02 7.527e-03  1.436 0.154659  
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.19 on 84 degrees of freedom
Multiple R-squared:  0.4299,    Adjusted R-squared:  0.3281 
F-statistic: 4.223 on 15 and 84 DF,  p-value: 9.494e-06
```

Dans le modèle, les 3 nouvelles fonctionnalités d'interaction "Energy\_Danceability", "BPM\_Loudness", "Acousticness\_Speechiness" sont statistiquement significatives au niveau 0,05.


La valeur  $R^2$  est de 0,4299, ce qui signifie qu'environ 43 % de la variabilité de la "Popularité" peut être expliquée par le modèle.

```
> vif_values <- car::vif(model_3)
>
> # Print the VIF values
> print(vif_values)
```

	Valence	Duration	Top.Genreadult.standards
Liveness	2.605316	1.413633	6.976620
1.198408			
Top.Genrealternative	3.921957	3.559866	3.170990
5.459471			
Top.Genrepop	14.201970	1.618802	Total.Followers
7.193583			1.357558
Energy_Danceability	2.072949	1.540151	
3.917992			

Les 3 nouvelles fonctionnalités d'interaction ont des valeurs VIF comprises entre 1 et 5, ce qui suggère qu'elles ont une corrélation modérée avec d'autres variables du modèle.  
On teste les hypothèses du modèle :

## 1. Linéarité




La plupart des variables sont non linéaires avec "Popularity", il signifie que l'hypothèse de Linéarité est violée.

## 2. Indépendance

L'hypothèse d'observation indépendante stipule que chaque observation de l'ensemble de données est indépendante. Comme chaque variable est indépendante les unes des autres, l'hypothèse d'indépendance n'est pas violée.

### 3. Normalité des résidus



```
> shapiro.test(residuals_3)
```


```
Shapiro-Wilk normality test
```

```
data: residuals_3  
W = 0.99247, p-value = 0.8544
```

On voit bien sur les figures et le test Shapiro Wilk, avec la valeur  $p = 0.8544 > 0.05$ , que les résiduels suivent la loi normale. Il suggère que l'hypothèse de normalité soit remplie pour ce modèle.

### 4. Constant Variance

Residuals vs. Fitted Values



```
> bptest(model_3)

studentized Breusch-Pagan test

data: model_3
BP = 26.97, df = 15, p-value = 0.02898
```

Le résultat du test de Breusch Pagan indiquant que la valeur  $p = 0,02898 < 0,05$ , il suggère que l'hypothèse de Constant Variance ne soit pas remplie pour ce modèle.

## 6. Évaluation des modèles

L'évaluation des modèles de régression est cruciale pour évaluer leurs performances et déterminer dans quelle mesure ils capturent la relation entre les variables indépendantes et la variable dépendante. Il utilise quelques mesures clés pour évaluer le modèle :

### 1. R au carré (coefficient de détermination) :

- R au carré représente la proportion de variance de la variable dépendante expliquée par les variables indépendantes du modèle.
- Il va de 0 à 1, des valeurs plus élevées indiquant un meilleur ajustement (plus de variance expliquée par le modèle).

### 2. Erreur quadratique moyenne (RMSE) :

- RMSE est la racine carrée de MSE.
- Il est plus facile à interpréter dans les mêmes unités que la variable dépendante, ce qui en fait une mesure plus intuitive de l'erreur de prédiction moyenne.

### 3. Erreur absolue moyenne (MAE) :

- MAE calcule la différence absolue moyenne entre les valeurs prédictes et les valeurs réelles.
- Il est moins sensible aux valeurs aberrantes que MSE/RMSE, car il utilise des différences absolues au lieu de carrés.
- MAE représente l'ampleur moyenne des erreurs dans les mêmes unités que la variable dépendante.

<pre>&gt; predictions &lt;- predict(model_1, newdata = data) &gt; &gt; # Calculate the residuals &gt; residuals &lt;- data\$Popularity - predictions &gt; &gt; # Calculate RMSE &gt; rmse &lt;- sqrt(mean(residuals^2)) &gt; print(paste("RMSE: ", rmse)) [1] "RMSE: 12.8160532387548" &gt; &gt; # Calculate MAE &gt; mae &lt;- mean(abs(residuals)) &gt; print(paste("MAE: ", mae)) [1] "MAE: 10.3884002862376"</pre>	<pre>&gt; predictions &lt;- predict(model_2, newdata = data) &gt; &gt; # Calculate the residuals &gt; residuals &lt;- data\$Popularity - predictions &gt; &gt; # Calculate RMSE &gt; rmse &lt;- sqrt(mean(residuals^2)) &gt; print(paste("RMSE: ", rmse)) [1] "RMSE: 9.92628151172089" &gt; &gt; # Calculate MAE &gt; mae &lt;- mean(abs(residuals)) &gt; print(paste("MAE: ", mae)) [1] "MAE: 7.64614365460246"</pre>	<pre>&gt; predictions &lt;- predict(model_3, newdata = data) &gt; &gt; # Calculate the residuals &gt; residuals &lt;- data\$Popularity - predictions &gt; &gt; # Calculate RMSE &gt; rmse &lt;- sqrt(mean(residuals^2)) &gt; print(paste("RMSE: ", rmse)) [1] "RMSE: 10.2564570711803" &gt; &gt; # Calculate MAE &gt; mae &lt;- mean(abs(residuals)) &gt; print(paste("MAE: ", mae)) [1] "MAE: 8.22444744691153"</pre>
--	--	--

- Modèle 1 : RMSE est d'environ 12,82 et MAE est d'environ 10,39. Il signifie qu'en moyenne, les prédictions du modèle sont éloignées d'environ 12,82 unités des valeurs réelles (en termes de RMSE) et d'environ 10,39 unités en termes de MAE.
- Modèle 2 : RMSE est d'environ 9,93 et MAE est d'environ 7,65. Ce modèle fonctionne mieux que le modèle 1 car il a des valeurs RMSE et MAE inférieures.
- Modèle 3 : RMSE est d'environ 10,26 et MAE est d'environ 8,22. Ce modèle est légèrement moins performant que le modèle 2 mais meilleur que le modèle 1.

	RMSE	MAE	R^2
Modèle 1	12.82	10.39	0.11
Modèle 2	9.93	7.65	0.47
Modèle 3	10.26	8.22	0.43

Le modèle 2 offre les meilleures performances parmi les trois modèles car il présente les valeurs RMSE et MAE les plus basses. Cela signifie que les prédictions du modèle 2 sont, en moyenne, plus proches des valeurs réelles que celles des deux autres modèles.

## 7. Conclusion

- L'analyse exploratoire des données est utile pour sélectionner des variables numériques et catégorielles pour les régressions linéaires modèles.
- L'ajustement de plusieurs modèles de régression linéaire peut nécessiter des essais et des erreurs pour sélectionner les variables qui correspondent à un modèle précis tout en conservant les hypothèses du modèle.
- Le modèle utilisait une régression linéaire multiple expliquant seulement 47 % (43 % avec la transformation de données) de la variation de la popularité des chansons. Il est nécessaire d'explorer d'autres types de modèles mieux adaptés à cet jeu de données.